

SIPECA-B: presentando un *benchmark* de series temporales de datos reales para la predicción del tráfico

P. A. Castillo¹, A. Fernández-Ares¹, M. G. Arenas¹, A. M. Mora¹,
P. García-Sánchez¹, P. de las Cuevas¹, V. M. Rivas²

Resumen—

En el ámbito de la gestión del tráfico no existen benchmarks públicos obtenidos a partir de datos reales disponibles para la comunidad, de forma que puedan probar sus métodos de extracción de información y comparar sus resultados con los obtenidos por otros investigadores. En este trabajo se presenta el benchmark SIPECA-B, un conjunto de series temporales obtenidas a partir de la monitorización del tráfico en varios puntos de la red de carreteras andaluza. Se trata de datos reales relativos al número de vehículos que han pasado por ciertos puntos a lo largo de varios meses. Las series de datos se facilitan en formatos sencillos y ampliamente extendidos y se han dejado disponibles en un repositorio público. El objetivo de este trabajo es ofrecer acceso y detalles del benchmark propuesto a otros investigadores, así como unos resultados preliminares con varios métodos de predicción que sirvan para la comparación de futuros resultados publicados en el área de la gestión y predicción del tráfico.

Palabras clave—Benchmarks, Predicción del flujo de tráfico, Bluetooth, Series temporales

I. INTRODUCCIÓN

En diversos campos existen benchmarks estándar que son utilizados ampliamente por los investigadores, tal como el Proben1 [?] en el área de las redes neuronales artificiales o el benchmark de la competición de optimización funcional del congreso IEEE Congress on Evolutionary Computation [?].

Sin embargo, en otros campos hay una necesidad de este tipo de problemas reales, como por ejemplo en el área de la gestión del tráfico. En este área, por la tipología de los problemas, existe una dificultad de obtener datos reales. En algunos casos por la dificultad de disponer de los datos en un formato adecuado [?], y en otros casos por tratarse de datos comerciales confidenciales [?] obtenidos, p.ej. en peajes de autopistas [?]. Esto hace que sólo en ciertos trabajos de investigación se puedan usar, con lo que es imposible comparar resultados con otros.

Es por esto que muchos investigadores presentan sus trabajos usando simuladores de tráfico [?] o benchmarks artificiales para obtener datos con los que trabajar (aplicarles algoritmos de extracción de información o predicción). Entre estos benchmarks sintéticos cabe destacar:

- El *Linear Road Benchmark*, que utiliza el *MIT Trac Simulator* para simular el movimiento de vehículos en un peaje [?].
- El *DynaMark Benchmark*, que simula el movimiento de usuarios, actualizando su posición con cierta periodicidad [?].
- El *COST Benchmark*, que simula objetos móviles y actualiza su posición 2D periódicamente [?].
- El *BerlinMOD Benchmark*, que simula datos espacio-temporales del movimiento de vehículos sobre una red de carreteras real [?].
- El *GSMARK Benchmark*, que genera datos a partir de una carretera real sobre la que se simula el movimiento de vehículos [?].
- El benchmark público del *Transport and Logistic Division of the Department of Urban Planning and Environment*, compuesto por datos reales de la posición GPS de 1500 taxis y 400 camiones circulando por las calles de Estocolmo [?].

Así pues, hay una necesidad clara de benchmarks estándar basados en datos reales del tráfico, así como reglas o convenciones para usarlos en la evaluación de métodos de predicción en la gestión del tráfico. Una forma de arreglar este problema es fomentar que los investigadores o bien usen benchmarks estándar o bien publiquen no sólo los resultados obtenidos sino también los datos del problema utilizado y su descripción detallada.

Como se ha indicado, no basta con un conjunto de problemas y reglas, sino que hay que asegurarse de que los resultados obtenidos al utilizar dichos problemas sean comparables y reproducibles. Para ello hay que disponer de unos resultados de referencia que sirvan de base para las comparaciones.

Disponiendo del benchmark a partir de datos reales, las reglas de aplicación/documentación, y los resultados base para la comparación, se facilita el trabajo de los investigadores, asegurando la reproducibilidad y comparabilidad de resultados [?].

En este sentido, SIPECA-B pretende ser un primer paso hacia un benchmark estándar para el área de la gestión del tráfico, compuesto de diversas series temporales obtenidas a partir de datos reales del paso de vehículos por diversos puntos de las carreteras andaluzas. Su disponibilidad facilita el acceso a los investigadores a datos reales de movilidad en formatos sencillos y ampliamente extendidos.

¹Depto de Arquitectura y Tecnología de Computadores. CITIC. Univ. Granada. e-mail: pacv@ugr.es

²Depto de Informática. Escuela Politécnica Superior de Jaén. Univ. Jaén

Además, siguiendo las recomendaciones de Prechelt [?], se proponen una serie de reglas para llevar a cabo la aplicación de métodos de predicción a estos problemas.

El hecho de preferir problemas basados en datos reales frente a datos artificiales o sintéticos hace que la investigación y sus resultados sean relevantes en al menos un ámbito [?], [?].

El resto del trabajo está organizado como se indica a continuación: En la Sección ?? se presenta el proyecto de investigación dentro del cual se enmarca este trabajo y se detalla cómo se han obtenido los datos para construir las series temporales. La Sección ?? propone una serie de medidas de error a utilizar al llevar a cabo las predicciones, de forma que los resultados sean comparables con los presentados por otros autores. A continuación se presenta un breve estado del arte en métodos de predicción de series temporales (Sección ??). En la Sección ?? se presenta una serie de resultados experimentales utilizando algunos de los métodos de predicción y medidas de error propuestas ante varias series temporales. Finalmente, la Sección ?? presenta una serie de conclusiones obtenidas tras el desarrollo de este trabajo, seguidas de trabajos futuros.

II. OBTENCIÓN DE LOS DATOS PARA LAS SERIES TEMPORALES

A continuación se describe el proyecto de investigación con el que se obtuvieron los datos del paso de vehículos por diversos tipos de vía. Posteriormente se comentan los principios generales y los objetivos del benchmark SIPESCA-B. Por último, se describen las series temporales que se han utilizado en los experimentos presentados en la Sección ??.

A. La obtención de los datos. El proyecto SIPESCA

El presente trabajo se enmarca dentro del proyecto *"Sistema de Información y Predicción de bajo coste y autónomo para conocer el Estado de las Carreteras en tiempo real mediante dispositivos distribuidos"* (SIPESCA) [?], [?]. El objetivo principal de este proyecto es conseguir un sistema de información de bajo coste, de rápida implantación y de alta fiabilidad, tal que informe sobre las condiciones del tráfico en tiempo real, no sólo para las instituciones y organismos encargados de la regulación y control del tráfico, sino también a usuarios particulares (por ejemplo a través de alertas móviles o mediante web).

La implantación de los dispositivos de monitorización de SIPESCA nos ha permitido recoger una gran cantidad de datos del paso de vehículos por diversas vías de diferente tipo (autovías, carreteras y calles en Granada y varios pueblos en el área metropolitana de Sevilla). A partir de estos datos, hemos construido diversas series temporales del paso de vehículos con las que podemos predecir el flujo de tráfico que tendrán las vías monitorizadas.

La captación de datos se basa en la detección de

dispositivos bluetooth (BT) y wifi, lo que nos proporciona una descripción de las condiciones de tráfico en tiempo real y un conjunto de datos válidos para utilizarlos con técnicas de predicción de series temporales. La captación de datos incluye tanto dispositivos BT empotrados en algún tipo de vehículo como dispositivos de usuarios particulares que lleven el BT o wifi activado. El principal dato recolectado de cada dispositivo es la dirección MAC (*media access control* o dirección física, es un identificador de 48 bits que corresponde de forma única a una tarjeta o dispositivo de red) que se encripta y se almacena, lo que permite identificar de forma unívoca el dispositivo, pero no el usuario, por lo que la privacidad de la persona usuaria del dispositivo está totalmente reservada. Este método de recolección permite la identificación del dispositivo en varios puntos de la ciudad, lo que puede dar una idea del tipo de desplazamientos que ese dispositivo ha realizado.

Concretamente el dispositivo utilizado para la captación de datos es Intelify¹, que ofrece una solución compacta para captar dispositivos BT y wifi, y transmitir la información a un servidor remoto manteniendo un índice de detección adecuado (tiene un 8.5% de error en la captación). Se trata de un dispositivo autónomo que puede ser instalado en el área donde se desean captar datos y dispone de varios sensores para captar la información y enviarla a través de una conexión 3G².

La información captada se organiza en una entidad denominada "paso". Un paso es un dispositivo detectado en un determinado nodo de captación a una determinada hora de inicio y que se ha terminado de captar a una determinada hora de fin. Así, con los datos de nodo, dispositivo, hora de inicio y hora de fin se puede categorizar un paso. La MAC del dispositivo incluye la identificación de la marca, modelo y algunas características más del dispositivo que ayuda a su categorización dentro del abanico de dispositivos captados.

El objetivo del proyecto es obtener información acerca de los flujos de tráfico que se producen en una zona, permitiendo poder gestionar de manera óptima las decisiones de desplazamiento por parte de los ciudadanos o desarrollar planes de actuación concretos en cada caso.

B. El benchmark SIPESCA-B

Con la publicación del benchmark SIPESCA-B buscamos ofrecer un conjunto de series temporales obtenidas a partir de datos reales a los investigadores que trabajan en el ámbito de la gestión y predicción del tráfico.

Las series de datos se facilitan en texto plano, en formatos sencillos y ampliamente extendidos (CSV, JSON, ARFF y XML) y se han dejado disponibles en el repositorio público de código

¹<http://www.intelify.net>

²<http://es.wikipedia.org/w/index.php?title=3G>

Fig. 1. Representación de la serie temporal de ejemplo `days_1351591695721_2012-11-19_2013-03-01_103_55-3071_.csv`

<https://github.com/Sipesca/Datasets> bajo la licencia libre ODC Open Database License (ODbL)³ que permite copiar y distribuir los datos, crear trabajos a partir de ellos, y transformar esos datos, siempre que se distribuyan los datos obtenidos usando la misma licencia.

Junto con los conjuntos de datos y las reglas básicas, se ofrecen una serie de predicciones realizadas con varias de las series temporales y usando varios métodos de predicción. Estas medidas se pueden usar como base para las comparaciones.

Al usar este benchmark, esperamos mejorar la reproducibilidad de los experimentos presentados, de forma que en el futuro, otros investigadores puedan repetir los experimentos. Este es un punto importante, ya que un aspecto esencial de la ciencia es precisamente la posibilidad de repetir cualquier experimento para comprobar la validez del mismo.

Por otro lado, en muchos trabajos se hace referencia a problemas conocidos de una forma algo difusa, como "se ha usado el problema Glass del Proben1" [?]. Estas referencias resultan confusas, ya que puede haber varias versiones (incluso diferentes entre trabajos del mismo autor). En este sentido, SIPESCA-B busca facilitar tanto el uso de problemas bien documentados, como la comparabilidad de los resultados obtenidos por distintos investigadores con diferentes métodos. Al disponer de los mismos datos, tan solo hay que indicar las series utilizadas y detallar el método y parámetros elegidos.

C. La publicación de las series en el repositorio

Como se ha indicado, el benchmark se deja disponible en el repositorio público de código anteriormente comentado⁴, ofreciendo 4 tipos de archivos

distintos: CSV, JSON, ARFF y XML.

Se presentan series con 5 tipos de intervalos de tiempo (de mayor a menor amplitud):

- Semanas (W)
- Días (D)
- Horas (H)
- 30 minutos (30m)
- 15 minutos (15m)

Se presentan tanto las series sin marcas de tiempo como las series con marcas temporales. Estas últimas se han incluyen en la carpeta TS correspondiente al tipo de intervalo y en cada entrada de la serie la fecha sigue un formato YYYY-MM-DD HH:mm:ss.

Por ejemplo, el archivo:

`days_1351591695721_2012-11-19_2013-03-01_103_55-3071_.csv`

corresponde con la serie en formato CSV que abarca desde el 2012-11-19 al 2013-03-01, con intervalo de días, con marcas de tiempo y cuyos datos se han obtenido con el nodo con id 1351591695721. Además, esta serie incluye 103 valores, con el mínimo en 55 y el máximo a 3071, y no lleva marca de tiempo (TS). La serie temporal contenida en este archivo de ejemplo se muestra gráficamente en la Figura ??.

Por otro lado, debido al problema en cuestión y sobre todo al tipo de hardware utilizado, hay momentos en que los nodos no detectan ningún dispositivo (bien porque haya un periodo sin paso de vehículos, o bien porque el nodo de monitorización haya dejado de funcionar). En esos casos, el número de vehículos detectado es cero. Es por esto que se presentan series con valores ausentes, que se notan con el valor AN en el nombre. Los valores ausentes se marcan con el valor NA en los instantes correspondientes en la serie.

Por último, cabe destacar que no solo se ofrecen las series descritas, sino que se han dejado disponibles los datos en bruto (carpeta *raw*), sin procesar ni

³<http://opendatacommons.org/licenses/odbl>

⁴<https://github.com/Sipesca/Datasets>

partir en intervalos. Estos datos, junto con las funciones en lenguaje R de extracción y completado de series temporales desarrolladas e incluidas en la carpeta *scripts* del repositorio permitirán a cualquier investigador que tome los datos en bruto (*raw*) para generar nuevas series según sus necesidades (no se restringe a las que hemos generado).

III. MEDIDAS DE ERROR

En la literatura se pueden encontrar muchas medidas de error diferentes (también llamadas funciones de error o funciones de coste) al mostrar los resultados obtenidos con los métodos de predicción.

Una de las más conocidas y utilizadas es la del error cuadrático, y derivada de ésta, la del error cuadrático medio (ver la ecuación ??), que presenta la ventaja de ser independiente del tamaño del conjunto de datos. Sin embargo, en muchos trabajos de investigación se utilizan otras muchas, y en ocasiones con pequeñas diferencias introducidas en las ecuaciones utilizadas.

En cualquier caso, se recomienda utilizar ecuaciones estándar ampliamente aceptadas y utilizadas por la comunidad⁵ para poder comparar los resultados obtenidos con los presentados en otros trabajos de investigación utilizando otros métodos predictivos. Es por esto que junto con el benchmark, se aportan diferentes medidas de error estándar (ecuaciones ?? a ??) que se pueden encontrar implementadas en herramientas como Weka⁶ [?] o R⁷ [?].

Concretamente se proponen las siguientes medidas:

- Error absoluto medio (*Mean Absolute Error*, MAE):

$$MAE = \frac{1}{n} \sum_{i=1}^n |p_i - o_i| \quad (1)$$

- Error absoluto porcentual medio (*Mean Absolute Percentage Error*, MAPE):

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{p_i - o_i}{o_i} \right| \quad (2)$$

- Error cuadrático medio (*Mean Squared Error*, MSE):

$$MSE = \frac{1}{n} \sum_{i=1}^n (p_i - o_i)^2 \quad (3)$$

- Raíz del error cuadrático medio (*Root Mean Squared Error*, RMSE):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (p_i - o_i)^2} \quad (4)$$

⁵<http://www.gepssoft.com/gxpt4kb/Chapter10/Section3/Introduction.htm>

⁶<http://wiki.pentaho.com/display/DATAMINING>

⁷<https://www.otexts.org/fpp/2/5>

- Error absoluto relativo (*Relative absolute error*, RAE):

$$RAE = \frac{\sum_{i=1}^n |p_i - o_i|}{\sum_{i=1}^n |p_{i-1} - o_i|} \quad (5)$$

- Raíz del error cuadrático relativo (*Root relative squared error*, RRSE):

$$RRSE = \sqrt{\frac{\sum_{i=1}^n (p_i - o_i)^2}{\sum_{i=1}^n (p_{i-1} - o_i)^2}} \quad (6)$$

- Porcentaje de predicciones correctas en cambios de dirección (*Direction accuracy*, DA):

$$DA = \frac{1}{N} \sum_{i=1}^n a_i$$

$$a_i = \begin{cases} 1, & (o_i - o_{i-1})(p_i - p_{i-1}) > 0 \\ 0, & \text{en otro caso} \end{cases} \quad (7)$$

donde o_i es el dato observado en tiempo $i = 1, \dots, n$ y p_i es la predicción de o_i obtenida.

IV. MÉTODOS DE PREDICCIÓN DE SERIES TEMPORALES

La predicción de series temporales es una línea de investigación madura cuyo objetivo es obtener modelos predictivos a partir de series temporales usando métodos lineales y no lineales. El método lineal más conocido es ARIMA[?]. Se trata de un modelo simple cuyo funcionamiento está ampliamente demostrado, pero no funciona muy bien con muchas aplicaciones de series temporales reales puesto que su ajuste es una tarea compleja que hay que realizarla utilizando conocimiento experto [?].

Por otro lado, los modelos no lineales [?], [?], [?], [?] funcionan mejor ante aplicaciones reales, aunque su uso es complejo [?]. De ahí que existan propuestas donde se recomienda que se le de prioridad a la facilidad de uso frente a otros aspectos más técnicos [?]. Entre los modelos no lineales, destacan varias técnicas de Soft-Computing, [?], [?], Técnicas Fuzzy [?], [?], redes neuronales [?], [?], Regresión [?], y sistemas expertos [?].

Por otro lado, existen algunos métodos más complejos, basados en varias metaheurísticas [?], [?], [?]. Cabe destacar entre estos el algoritmo L-Co-R [?], [?] como método no lineal que utiliza redes de base radial (RBFs) para determinar de forma cooperativa el lag (los datos de entrada de la serie temporal) y la predicción de la serie temporal a la que se aplique el algoritmo.

Más adelante (subsección ??) se ofrece una serie de resultados obtenidos usando varias series temporales con algunos de estos métodos citados disponibles en herramientas de código abierto.

V. RESULTADOS EXPERIMENTALES OBTENIDOS CON EL BENCHMARK SIPESCA-B

En esta sección se presenta una serie de resultados utilizando varios métodos de predicción con las

Fig. 2. Mapa de localización de los tres dispositivos de monitorización con los que se recogieron los datos para construir las tres series temporales.

Fig. 3. Número de vehículos detectados por hora en cada uno de los tres nodos.

series temporales descritas en la subsección ?? como ejemplo. Estos resultados se aportan como base para realizar comparaciones en el futuro con otros métodos (subsección ??).

Se han seleccionado tres métodos de predicción, entre los que se incluyen métodos lineales y no lineales. Concretamente, se muestran los resultados obtenidos con ARIMA, L-Co-R, y el modelo Support Vector Machine (SVM) [?] con perceptrones multicapa (MLP) [?] de la herramienta Weka [?].

Todos ellos, excepto L-Co-R, se pueden utilizar a través de las herramientas Weka⁸ o R⁹ y son ampliamente conocidos, de forma que cualquier investigador puede reproducir los experimentos y comprobar los resultados, y en el futuro, usar los mismos métodos para comparar con sus modelos.

En todos los casos, se han generado modelos para predecir las últimas 24h del flujo de tráfico en varios puntos.

A. Descripción de las series temporales utilizadas

Para la parte experimental, se han seleccionado tres series temporales, correspondientes a los dispositivos marcados en el mapa mostrado en la Figura ???. Estas series incluyen los datos entre el 31 de diciembre de 2013 y el 20 de enero de 2014, y se han dejado disponibles en la carpeta *research*¹⁰ del repositorio.

Cada entrada de la serie representa el número de vehículos detectado cada hora en cada nodo de monitorización, de forma que cada serie está compuesta por 505 entradas.

Se eligió una hora como intervalo para mostrar algunas características del tráfico en este área de la ciudad de Granada a lo largo del día (se alcanzan picos hacia mediodía entre las 13h y las 15h). Este efecto se muestra en la Figura ??, que representa las tres series contempladas.

Hay que hacer notar que el periodo de tiempo que abarcan las series elegidas comprende los primeros días del año, vacaciones, y corresponde con una de

⁸<http://www.cs.waikato.ac.nz/ml/weka/>

⁹<http://www.r-project.org/>

¹⁰<https://github.com/Sipesca/Datasets/tree/master/research/sipesca-b>

TABLA I

Medidas de error para las series A, B y C utilizadas en estos experimentos. En negrita se resalta el mejor resultado para cada caso. En todos los casos, salvo para DA, el mejor resultado corresponde con el menor valor de las medidas de error.

Dataset A							
	MAE	MAPE(%)	MSE	RMSE	RAE(%)	RRSE(%)	DA(%)
ARIMA	174,67	124, 11	45751,58	213,90	218,81	214,34	54, 17
SVM-MLP	211, 72	78,96	90299, 95	300, 50	265, 23	301, 12	79,17
L-Co-R	288, 36	84, 81	146400, 96	382, 62	361, 24	383, 42	45, 83
Dataset B							
	MAE	MAPE(%)	MSE	RMSE	RAE(%)	RRSE(%)	DA(%)
ARIMA	420, 50	433, 13	259220, 81	509, 14	507, 96	474, 90	54, 17
SVM-MLP	132,78	230,87	30287,99	174,03	160,39	162,33	58,33
L-Co-R	204, 81	320, 63	76271, 78	276, 17	247, 41	257, 60	54, 17
Dataset C							
	MAE	MAPE(%)	MSE	RMSE	RAE(%)	RRSE(%)	DA(%)
ARIMA	18, 03	416, 08	507,47	22,53	260, 76	209,67	37, 50
SVM-MLP	16,42	283, 82	508, 19	22,54	237,59	209,82	41, 67
L-Co-R	17, 48	183,07	571, 37	23, 90	252, 84	222, 48	54,17

las "operaciones salida" de la DGT, que el año pasado supuso más de 3.3 millones de despazamientos. Así pues, se trata de series en las que muchos vehículos modificaron el patrón habitual del tráfico en esa zona.

En los experimentos llevados a cabo con las tres series descritas se han usado los primeros 481 valores de la serie para entrenar los diferentes métodos y poder construir el modelo predictivo, mientras que los 21 valores restantes se han utilizado para comprobar la bondad de la predicción obtenida. La predicción se genera con un horizonte de 1, es decir, conocidos los datos de la serie con n elementos, el algoritmo predice el elemento $n + 1$.

B. Experimentos y resultados obtenidos

Para cada método y cada serie, se han calculado las medidas de error propuestas en la Sección ?? para poder comparar la predicción de los diferentes métodos.

Los resultados mostrados del algoritmo L-Co-R son medias de error de 30 ejecuciones con cada una de las series temporales estudiadas.

La Tabla ?? muestra los diferentes valores de error para cada uno de los métodos y cada serie. Se muestra destacado en negrita el mejor (menor) valor obtenido para cada nodo y cada medida de error.

Aunque no es el propósito de este trabajo, se puede apreciar que los mejores resultados se han obtenido con el método SVM-MLP.

VI. CONCLUSIONES

Existen áreas, como la gestión del tráfico, en las que los investigadores tienen una necesidad de disponer de benchmarks estándar para ser utilizados con sus métodos de predicción. Principalmente esto es debido a la dificultad en obtener datos reales e incluso, a la dificultad de disponer de los datos en un formato adecuado.

En este trabajo se ha presentado el benchmark SIPESCA-B, un conjunto de series temporales obtenidas a partir de la monitorización del tráfico en varios puntos de la red de carreteras andaluza den-

tro del proyecto SIPESCA [?], [?]. Los datos (reales) se han obtenido monitorizando el paso de dispositivos con el BT o el wifi encendido por ciertos puntos en autovías, carreteras y calles a lo largo de varios meses.

Las series temporales creadas se han dejado accesibles a toda la comunidad científica en el repositorio público <https://github.com/Sipesca/Datasets> bajo la licencia libre ODC Open Database License.

Esperamos que este benchmark sirva como un estándar y ayude a los investigadores que trabajan en el área de la gestión y predicción del tráfico para presentar sus resultados, haciéndolos comparables y reproducibles.

En este sentido, se facilita una serie de resultados de referencia que servirán de base para las comparaciones. Para la parte experimental del trabajo se han utilizado varias de estas series temporales reales y se ha realizado un estudio para predecir a corto plazo (un día, los 24 valores siguientes) cuál será el flujo de tráfico en cada uno de los nodos. Se han seleccionado tres métodos de predicción de diferente tipo (basados en metaheurísticas y de tipo estadístico), validados en la bibliografía, con los que se han calculado 7 medidas de error.

Como se puede ver en la Tabla ??, en general los mejores resultados de predicción se han obtenido con el método SVM-MLP. En gran parte de los casos obtiene medidas de error más bajas ante las tres series temporales consideradas.

Finalmente, este trabajo abre un abanico de posibilidades de análisis de la gran cantidad de datos captados y la posibilidad de desarrollar y aplicar métodos de predicción no sólo a corto plazo, sino a medio y largo plazo, lo que facilitará la tarea de previsión del flujo de tráfico en las vías monitorizadas y por consiguiente una mejor gestión del tráfico en dichas vías por parte de las autoridades competentes.

Como trabajos futuros, se continuarán obteniendo datos del paso de vehículos para generar nuevas series temporales más completas, abarcando periodos de tiempo mayores. Los nuevos datos y las nuevas se-

ries obtenidas se dejarán accesibles en el repositorio indicado.

AGRADECIMIENTOS

Este trabajo se está desarrollando gracias a la financiación de los proyectos TIN2011-28627-C04-02, GENIL PYR-2014-17, PETRA (SPIP2014-01437 de la Dirección General de Tráfico), MSTR (PRY142/14 de la Fundación Pública Andaluza, Centro de Estudios Andaluces en la IX Convocatoria de Proyectos de Investigación), y del proyecto FEDER de la Unión Europea con título "*Sistema de Información y Predicción de bajo coste y autónomo para conocer el Estado de las Carreteras en tiempo real mediante dispositivos distribuidos*" (SIPEsCa) del Programa Operativo FEDER de Andalucía 2007-2013. Asimismo, queremos mostrar nuestro agradecimiento al personal e investigadores de la Agencia de Obra Pública de la Junta de Andalucía, Consejería de Fomento y Vivienda, por su dedicación y profesionalidad.

REFERENCIAS

- [1] Lutz Prechelt. PROBEN1 - A Set of Benchmarks and Benchmarking Rules for Neural Network Training Algorithms. Technical Report 21/94, 38 pages, Fakultät für Informatik, Universität Karlsruhe, September 1994 <http://page.mi.fu-berlin.de/prechelt/Biblio/1994-21.pdf>
- [2] J. J. Liang, B-Y. Qu, P. N. Suganthan, Problem Definitions and Evaluation Criteria for the CEC 2014 Special Session and Competition on Single Objective Real-Parameter Numerical Optimization, Technical Report 201311, Computational Intelligence Laboratory, Zhengzhou University, Zhengzhou China and Technical Report, Nanyang Technological University, Singapore, December 2013.
- [3] Pedro García-Fernández, Pedro A. Castillo, Pablo García-Sánchez, Maribel G. Arenas, Antonio M. Mora, Gustavo Romero, Juan J. Merelo y Victor M. Rivas. Monitorización del estado de las carreteras mediante un sistema autónomo y de bajo coste basado en la tecnología Bluetooth. SECURITAS VIALIS, Journal Europeo de Tráfico, Transporte y Seguridad Vial. Editorial Springer. Etrasa 2014. Vol. 17, pp. 139-160, ISSN: 1888-9697. 2014
- [4] P.A. Castillo, A. Fernández-Ares, P. García-Fernández, P. García-Sánchez, M.G. Arenas, A.M. Mora, G. Romero, V. Rivas, J.J. Merelo, Studying individualized transit indicators using a new low-cost information system. Handbook of Research on Embedded Systems Design. Alessandra Bagnato, Leandro Soares Indrusiak, Imran Rafiq Quadri, Matteo Rossi (Eds). Advances in Systems Analysis, Software Engineering, and High Performance Computing (ASASEHPC) Book Series. Industry and Research Perspectives on Embedded System Design. Chapter 16, pp. 388-407, ISBN 978-1466661943. IGI GLOBAL. DOI: 10.4018/978-1-4666-6194-3.ch016 2014
- [5] G.E. Box and G.M. Jenkins. Time series analysis: forecasting and control. Ed: San Francisco: Holden Day, 1976
- [6] E. Parras-Gutierrez, V.M. Rivas, M. Garcia-Arenas, M.J. del Jesus, Short, medium and long term forecasting of time series using the L-Co-R algorithm, Neurocomputing, Volume 128, 27 March 2014.
- [7] H. Tong, On a threshold model, Pattern recognition and signal processing, NATO ASI Series E: Applied Sc. 29 (1978) 575-586
- [8] H. Tong, Threshold models in non-linear time series analysis, Springer-Verlag, 1983.
- [9] K. Chan, H. Tong, On estimating thresholds in autoregressive models, Journal of Time Series Analysis 7 (3) (1986) 179-190.
- [10] P. Brockwell, R. Hyndman, On continuous-time threshold autoregression, International Journal of Forecasting 8 (2) (1992) 157-173.
- [11] Ian Witten and Eibe Frank. Data Mining: Practical Machine Learning Tools and Techniques. Morgan Kaufmann, 3 edition, 2011.
- [12] I.A Basheer, M Hajmeer, Artificial neural networks: fundamentals, computing, design, and application, Journal of Microbiological Methods, Volume 43, Issue 1, 1 December 2000, Pages 3-31
- [13] J. A. K. Suykens and J. Vandewalle. 1999. Least Squares Support Vector Machine Classifiers. Neural Process. Lett. 9, 3 (June 1999), 293-300.
- [14] Elisabet Parras-Gutierrez, M. G. Arenas, V. M. Rivas, M. J. del Jesus, Coevolution of lags and RBFNs for time series forecasting: L-Co-R algorithm, Soft Computing 16(6), (2012) 919-942.
- [15] J. De Gooijer, R. Hyndman, 25 years of time series forecasting, International Journal of Forecasting 22 (3) (2006) 443-473.
- [16] M. Clements, P. Franses, N. Swanson, Forecasting economic and financial time-series with non-linear models, International Journal of Forecasting 20 (2) (2004) 169-183.
- [17] B. Samanta, Prediction of chaotic time series using computational intelligence, Expert Systems with Applications 38 (9) (2011) 11406-11411.
- [18] S. Zhu, J. Wang, W. Zhao, J. Wang, A seasonal hybrid procedure for electricity demand forecasting in china, Applied Energy 88 (11) (2011) 3807-3815.
- [19] W. Qiu, X. Liu, H. Li, A generalized method for forecasting based on fuzzy time series, Expert Systems with Applications 38 (8) (2011) 10446-10453.
- [20] C. Wang, A comparison study between fuzzy time series model and arima model for forecasting taiwan export, Expert Systems with Applications 38 (8) (2011) 9296-9304.
- [21] T. Yu, K. Huarng, A neural network-based fuzzy time series model to improve forecasting, Expert Systems with Applications 37 (4) (2010) 3366-3372.
- [22] K. Kavaklioglu, Modeling and prediction of turkey's electricity consumption using support vector regression, Applied Energy 88 (1) (2011) 368-375.
- [23] P. K. Dash, A. C. Liew, S. Rahman, G. Ramakrishna, Building a fuzzy expert system for electric load forecasting using a hybrid neural network, Expert Systems with Applications 9 (3) (1995) 407-421.
- [24] Z. Tang, C. de Almeida, P. Fishwick, Time series forecasting using neural networks vs. box-jenkins methodology, Simulation 57 (5) (1991) 303-310.
- [25] H. Hippert, J. Taylor, An evaluation of bayesian techniques for controlling model complexity and selecting inputs in a neural network for short-term load forecasting, Neural Networks 23 (3) (2010) 386-395.
- [26] C. Lee, C. Ko, Time series prediction using rbf neural networks with a nonlinear time-varying evolution pso algorithm, Neurocomputing 73 (1-3) (2009) 449-460.
- [27] M. Perez-Godoy, P. Pérez-Recuerda, M. Frías, A. Rivera, C. Carmona, M. Parras, Co²rbfn for short and medium term forecasting of the extra-virgin olive oil price, in: J. González, D. Pelta, C. Cruz, G. Terrazas, N. Krasnogor (Eds.), Proceedings of Nature Inspired Cooperative Strategies for Optimization, Vol. 284, Springer Berlin/Heidelberg, 2010, pp. 113-125.
- [28] I.H. Witten and E. Frank and M.A. Hall, Data Mining: Practical Machine Learning Tools and Techniques, Third Edition (The Morgan Kaufmann Series in Data Management Systems). ISBN 978-0123748560. Morgan Kaufmann; 3 edition (January 20, 2011)
- [29] R.J. Hyndman and G. Athanasopoulos, Forecasting: principles and practice. ISBN 978-0987507105. OTexts. October 17, 2013
- [30] M. Khasheil and M. Bijari. Which Methodology is Better for Combining Linear and Nonlinear Models for Time Series Forecasting? Journal of Industrial and Systems Engineering, Vol. 4, No. 4, pp 265-285. 2011

- [31] M. Morzy. Mining Frequent Trajectories of Moving Objects for Location Prediction. Machine Learning and Data Mining in Pattern Recognition. Lecture Notes in Computer Science Volume 4571, pp 667-680. 2007
- [32] T. Brinkhoff. A framework for generating network-based moving objects. *GeoInformatica* 6(2), 153-180. 2002
- [33] G. Gidofalvi and E. Saqib. Developing a Benchmark for Using Trajectories of Moving Objects in Traffic Prediction and Management. In *Proc. of the Workshop on Movement Pattern Analysis. GIScience2010*, 2p, 2010
- [34] PLAISANT, C., FEKETE, J. D., AND GRINSTEIN, G. Promoting insight-based evaluation of visualizations: From contest to benchmark repository. *IEEE Transactions on Visualization and Computer Graphics* 14, 1, 120-134. 2008
- [35] B. Flyvbjerg. Curbing Optimism Bias and Strategic Misrepresentation in Planning: Reference Class Forecasting in Practice, *European Planning Studies*, Vol. 16, No. 1. 2008
- [36] Kriger, D., Shiu, S. and Naylor, S. Estimating Toll Road Demand and Revenue - A Synthesis of Highway Practice, NCHRP Synthesis 364, Transport Research Board. 2006
- [37] R. Bain. Error and optimism bias in toll road traffic forecasts. *J. Transportation*, N.5, pp. 469-482. DOI 10.1007/s11116-009-9199-7. 2009
- [38] Chao Shen and Yan Huang and Jason W. Powell. The Design of a Benchmark for Geo-stream Management Systems. In *GIS*, pp409-412. 2011
- [39] A. Arasu, M. Cherniack, E. Galvez, D. Maier, A. S. Maskey, E. Ryvkina, M. Stonebraker, and R. Tibbetts. Linear road: a stream data management benchmark. In *Proceedings of the Thirtieth international conference on Very large data bases - Volume 30, VLDB2004*, pages 480-491. VLDB Endowment, 2004
- [40] C. Duntgen, T. Behr, and R. H. Guting. Berlinmod: a benchmark for moving object databases. *The VLDB Journal*, 18:1335-1368. 2009
- [41] C. S. Jensen, D. Tiesyte, and N. Tradisaukas. The cost benchmark-comparison and evaluation of spatio-temporal indexes. In *DASFAA*, pages 125-140, 2006.
- [42] J. Myllymaki and J. Kaufman. Dynamark: A benchmark for dynamic spatial indexing. In *Proceedings of the 4th International Conference on Mobile Data Management, MDM2003*, pages 92-105, London, UK. Springer-Verlag. 2003